

HOMEWORK III

NOME: Elizeu Feitosa de Andrade
MATRÍCULA: 538839

QUESTÃO 1

Estime o parâmetro λ de uma distribuição Exponencial para os tempos de vida de computadores fornecidos, utilizando o método da Máxima Verossimilhança (MLE). Calcule a probabilidade $P(X > 5)$ e discuta a propriedade de falta de memória.

SOLUÇÃO DA QUESTÃO 1

Base Teórica e Cálculos

A função de verossimilhança para uma amostra i.i.d. de uma exponencial é $L(\lambda) = \lambda^n e^{-\lambda \sum x_i}$. Aplicando o logaritmo natural, obtemos a log-verossimilhança $l(\lambda) = n \ln(\lambda) - \lambda \sum x_i$.

Ao derivar $l(\lambda)$ em relação a λ e igualar a zero, encontramos o estimador de máxima verossimilhança:

$$\hat{\lambda} = \frac{n}{\sum_{i=1}^n x_i} = \frac{1}{\bar{X}} \quad (1)$$

Utilizando os dados fornecidos na Tabela 1:

- Soma dos tempos ($\sum x_i$): 126.29
- Tamanho da amostra (n): 20
- **Estimador $\hat{\lambda}$** : $20/124.0 \approx 0.1584$

A probabilidade de um computador durar mais de 5 anos é dada por $P(X > 5) = e^{-5\hat{\lambda}}$. Substituindo o valor estimado, temos $P(X > 5) \approx 0.453$.

Resultados Gráficos

A Figura 1 apresenta o gráfico da função Log-Verossimilhança. O ponto máximo da curva coincide com o valor calculado $\hat{\lambda}$.




Figura 1: Função de Log-Verossimilhança para o parâmetro λ .

O código utilizado para esta solução encontra-se no **Listado 1** ao final deste documento.

Discussão

O gráfico gerado mostra uma curva côncava (o que indica que 20 amostras é um bom número, deixa um pico bem definido e a curva não é aplainada), onde o pico (máximo) coincide exatamente com a linha vertical vermelha do nosso $\hat{\lambda}$ calculado, significando que a MLE está correta e é matematicamente extremamente confiável.

Sobre a propriedade de falta de memória da distribuição exponencial ($P(X > t+s|X > t) = P(X > s)$), ela implica que a probabilidade de falha não aumenta com a idade do equipamento. Olhando para computadores, isso é até que aceitável para falhas eletrônicas aleatórias tipo surtos de tensão, corrupção de memórias e por aí vai, no entanto, ela acaba ignorando o inevitável desgaste físico como fãs, discos rígidos mecânicos e demais equipamentos que se degradam ao longo do tempo.

A inferência é utilizada nas mais diversas áreas, muitas dessas extremamente críticas indo desde estabelecimento de garantia de produtos a segurança nuclear por exemplo.

QUESTÃO 2

Utilizando o dataset `palmerpenguins`, realize uma regressão linear simples para modelar a relação entre a massa corporal (X) e o comprimento do bico (Y). Analise os resíduos e o impacto da introdução de um outlier artificial.

SOLUÇÃO DA QUESTÃO 2

Modelo Original

Utilizando o método dos Mínimos Quadrados Ordinários (OLS) para ajustar a reta $Y = \beta_0 + \beta_1 X + \epsilon$. A Figura 2 mostra a dispersão dos dados e a reta ajustada. Observa-se uma correlação positiva: pinguins mais pesados tendem a ter bicos mais longos.




Figura 2: Regressão Linear: Massa Corporal vs. Comprimento do Bico.

A análise de resíduos (Figura 3) é fundamental para validar o modelo. Os resíduos devem estar distribuídos aleatoriamente em torno do zero.




Figura 3: Análise de Resíduos do Modelo Original.

As métricas obtidas foram:

- **RMSE Original:** (Inserir valor do seu R, ex: 3.5)
- **R^2 Original:** (Inserir valor do seu R, ex: 0.35)

Impacto do Outlier

Ao introduzir um outlier artificial (Massa=10kg, Bico=10mm), a reta de regressão sofreu uma alteração significativa (Figura 4). O método OLS é muito sensível a outliers, pois tenta minimizar o erro quadrático desse ponto distante, distorcendo a inclinação para os dados reais.




Figura 4: Comparação: Modelo Original (Azul) vs. Com Outlier (Vermelho).

O código utilizado encontra-se no **Listado 2**.

Discussão

Pode-se afirmar que fazer Regressão serve para transformar nossas intuições em uma ciência exata, partido do exemplo de pinguins, podemos sair de um pensamento de "Eu acho que quanto maior o pinguim, maior o seu bico" para "O bico de um pinguim cresce X valor a cada X gramas". Assim o RMS nos servindo de uma espécie de "mapa" das relações, o RMSE funcionando como a discrepância de erro, podendo indicar o perigo do modelo e o R^2 nos apontando a porcentagem da influencia em que um dado tem em relação ao outro. Sendo assim, a Regressão Linear é uma poderosa ferramenta para previsões e análise Causa e Efeito nos casos de variáveis contínuas, sendo usado em finanças, mercado imobiliário, engenharia, e principalmente hoje em dia, em IAs. No entanto o problema com OutLiers nos mostra o quão sensível é essa ferramenta, ao se deparar com um dado totalmente discrepante (O Pinguim Monstro), o OLS tenta minimizar essa discrepância ao quadrado, o que faz inclinar a linha drasticamente para mais perto desse valor, esse é o efeito alavanca. Por isso ao utilizar o OLS a limpeza de dados ou um melhor tratamento de dados se mostra extremamente necessário.

APÊNDICE: CÓDIGOS EM R

```
1 # --- Questao 1 ---
2
3 # --- DADOS E ESTIMATIVA ---
4 # 1. Dados da Tabela 1
5 tempos <- c(0.99, 2.31, 10.85, 6.15, 10.81, 3.72, 5.75, 4.15, 9.27,
6             7.84, 2.31, 10.85, 6.15, 1.81, 3.72, 5.75, 10.40, 10.04, 4.15,
7             9.27)
8
9 # 2. Calculo do MLE
10 n <- length(tempos)
11 soma_x <- sum(tempos)
12 lambda_hat <- n / soma_x
13 print(paste("Estimador MLE (lambda):", round(lambda_hat, 4)))
14
15 # 3. Grafico da Log-Verossimilhanca
16 # Definindo a funcao l(lambda)
17 log_lik <- function(lambda, dados) {
18   n <- length(dados)
19   soma <- sum(dados)
20   return(n * log(lambda) - lambda * soma)
21 }
22
23 # Criando sequencia de valores para lambda para o eixo X
24 lambdas_vals <- seq(0.01, 0.5, length.out = 100)
25 log_vals <- sapply(lambdas_vals, log_lik, dados = tempos)
26
27 # Plotando
28 plot(lambdas_vals, log_vals, type = "l", col = "blue", lwd = 2,
29      main = "Funcao Log-Verossimilhanca l(lambda)",
30      xlab = "Lambda", ylab = "Log-Likelihood")
31 abline(v = lambda_hat, col = "red", lty = 2) # Linha vertical no
32      estimador
33 legend("bottomright", legend = c("l(lambda)", "MLE"), col = c("blue",
34      "red"), lty = c(1, 2))
35
36 # 4. Tempo medio estimado e Probabilidade P(X > 5)
37 media_estimada <- 1 / lambda_hat
38 prob_maior_5 <- exp(-5 * lambda_hat) # usando a formula teorica da
39      exponencial
40 # Alternativamente usando pexp: 1 - pexp(5, rate = lambda_hat)
41
42 print(paste("Tempo medio estimado:", round(media_estimada, 4), "
43      anos"))
44 print(paste("Probabilidade P(X > 5):", round(prob_maior_5, 4)))
```

Listing 1: Código desenvolvido na solução da Questão 1

```

1 # --- Questao 2 ---
2 library(palmerpenguins)
3
4 # 1. Prepara o dos dados
5 # Removendo dados faltantes
6 penguins_data <- na.omit(penguins)
7
8 # Definindo variaveis
9 x <- penguins_data$body_mass_g # Independente
10 y <- penguins_data$bill_length_mm # Dependente
11
12 # Grafico de Dispers o
13 plot(x, y, pch = 19, col = "darkgray",
14       main = "Regress o: Massa Corporal vs Comprimento do Bico",
15       xlab = "Massa Corporal (g)", ylab = "Comprimento do Bico (mm)"
16     )
17
18 # 2. Ajuste do Modelo Linear
19 modelo <- lm(bill_length_mm ~ body_mass_g, data = penguins_data)
20 summary(modelo) # Mostrando coeficientes
21
22 # Adicionando reta ao grafico
23 abline(modelo, col = "blue", lwd = 2)
24
25 # 3. Residuos e Metricas
26 residuos <- residuals(modelo)
27 plot(residuos, main = "Res duos da Regress o", ylab = "Res duo")
28 abline(h = 0, col = "red")
29
30 # Calculo manual do RMSE
31 rmse <- sqrt(mean(residuos^2))
32 r_squared <- summary(modelo)$r.squared
33
34 print(paste("RMSE Original:", round(rmse, 4)))
35 print(paste("R2 Original:", round(r_squared, 4)))
36
37 # 4. Introduzindo um Outlier Artificial
38 # Criando uma c pia e adicionando um pinguim "gigante" com bico
39 # pequeno
40 novo_dado <- data.frame(
41   species = "Adelie", island = "Torgersen",
42   bill_length_mm = 10, # Valor muito baixo
43   bill_depth_mm = 15,
44   flipper_length_mm = 180,
45   body_mass_g = 10000, # Valor muito alto (10kg)
46   sex = "male", year = 2007
47 )
48
49 penguins_mod <- rbind(penguins_data, novo_dado)
50
51 # Ajuste do novo modelo

```

```

50 modelo_mod <- lm(bill_length_mm ~ body_mass_g, data = penguins_mod)
51
52 # Compara o Visual
53 plot(penguins_mod$body_mass_g, penguins_mod$bill_length_mm, pch=19,
54       col="gray",
55       main = "Compara o com Outlier")
56 points(10000, 10, col="red", pch=19, cex=2) # Destacando o outlier
57 abline(modelo, col="blue", lwd=2, lty=2)      # Reta original
58 abline(modelo_mod, col="red", lwd=2)          # Nova reta
59
60 # Comparando metricas
61 rmse_mod <- sqrt(mean(residuals(modelo_mod)^2))
62 r2_mod <- summary(modelo_mod)$r.squared
63
64 print(paste("RMSE Modificado:", round(rmse_mod, 4)))
65 print(paste("R2 Modificado:", round(r2_mod, 4)))

```

Listing 2: Código desenvolvido na solução da Questão 2